

Introdução ao PLN

Notebook: `introducao_pln.ipynb`

O que é Processamento de Linguagem Natural


Processamento de Linguagem Natural (PLN) é a área da Inteligência Artificial que ensina computadores a ler, entender, gerar e responder linguagem humana — a mesma que usamos para falar e escrever, cheia de ambiguidade, gírias e exceções, bem diferente de uma linguagem de programação (FERREIRA; LOPES, 2019).

Isso não é teoria distante: você já usa PLN o tempo todo, mesmo sem perceber — busca, tradução, corretor ortográfico, chatbot, assistente de voz e bem mais. Três desses exemplos, com fonte e número, você vê a seguir.

"A todo momento, estamos às voltas com programas de computador que interpretam e produzem texto e fala, corrigem o que digitamos, sugerem possibilidades de expressão, dialogam, traduzem, classificam dados linguísticos e buscam informações em gigantescos bancos de dados. Tudo isso faz parte do universo da Linguística Computacional e do processamento de linguagem natural."

FERREIRA; LOPES, sinopse oficial de *Para conhecer linguística computacional* (Contexto, 2019). Disponível em: books.google.com/books/about/Para_conhecer_linguistica_computacional.html?id=odtFEQAAQBAJ

PLN existe na fronteira entre três campos que evoluíram separadamente: a **Linguística** estuda como a língua funciona por dentro; a **Ciência da Computação** torna esse conhecimento processável em escala; e a **Inteligência Artificial** aprende os padrões da língua a partir de dados, em vez de regras escritas à mão. É por isso que as ferramentas mudam tanto ao longo do curso — cada técnica nova puxa mais peso de um desses três lados.



PLN na interseção entre Linguística, Ciência da Computação e Inteligência Artificial

O problema que o PLN resolve

Boa parte dos dados que empresas e instituições produzem todos os dias não tem estrutura nenhuma. Um **dado estruturado** tem formato predefinido — linhas e colunas de uma tabela, campos com tipo e relação conhecidos de antemão. Um **dado não estruturado** não segue esquema nenhum: um e-mail, um laudo médico, uma avaliação de produto, um post de rede social. Seu significado não pode ser extraído por uma regra simples — é preciso interpretar.

Estima-se que entre 80% e 90% de todos os dados produzidos no mundo sejam não estruturados, e a maior parte deles está em forma de texto (CASELI; NUNES, 2023).

Ter o dado não significa ter a informação. Um hospital pode armazenar digitalmente milhões de prontuários — mas perguntas simples como "quantos pacientes com mais de 60 anos tiveram um determinado sintoma nos últimos 5 anos?" continuam sem resposta se ninguém conseguir processar o texto desses prontuários. Sem PLN, esse volume de dados é computacionalmente invisível: existe, ocupa espaço, mas ninguém consegue perguntar nada a ele.

Por que isso é difícil

Para um computador, "vou pegar o ônibus" é fácil de tokenizar, mas entender o *sentido* exige lidar com problemas que não existem em código de programação:

- **Ambiguidade lexical** — "manga" pode ser fruta ou parte de uma roupa; só o contexto resolve.

- **Ambiguidade sintática** — "vi o cachorro correndo" — quem estava correndo, eu ou o cachorro?
- **Ironia e sarcasmo** — "que atendimento maravilhoso, esperei 2 horas" tem sentimento oposto ao literal.
- **Contexto e referência** — "Maria chegou. Ela estava atrasada." — o computador precisa saber que "ela" é a Maria.
- **Variação e informalidade** — "vc tá bem?", gírias regionais, erros de digitação propositais ou não.

Um breve histórico

PLN não nasceu com o ChatGPT. A área passou por fases bem diferentes (FERREIRA; LOPES, 2019; HOBSON; COLE; HANNES, 2019):

Fase	Ideia central	Limite
Baseada em regras (até ~1990)	Gramáticas e dicionários escritos à mão por linguistas	Não escala: cada exceção da língua exige uma nova regra
Estatística (~1990–2010)	Aprender padrões a partir de grandes quantidades de texto (corpora)	Depende de features desenhadas manualmente
Aprendizagem profunda (~2010–2018)	Redes neurais aprendem as próprias representações do texto	Exige muito dado e poder computacional
Modelos de linguagem em larga escala (2018–hoje)	Modelos como GPT e BERT, pré-treinados em bilhões de palavras	Caixa-preta, custo alto, viés dos dados de treino

Neste curso vamos passar por essa evolução na prática: começamos com processamento de texto "manual" e regras, seguimos para estatística (TF-IDF, embeddings) e chegamos em aprendizagem de máquina aplicada a PLN.

Aplicações no seu dia a dia

Não é uma promessa de futuro — é o que já roda por trás de coisas que você usa todo dia. Três exemplos com fonte confirmada:

Busca

Em outubro de 2019, o Google passou a usar o BERT (*Bidirectional Encoder Representations from Transformers*) para interpretar buscas — em vez de ler as palavras da sua pesquisa uma a uma, o modelo entende cada palavra em relação a todas as outras da frase. Pela própria estimativa do Google, isso passou a afetar uma em cada dez buscas em inglês nos EUA, e a empresa chamou de "o maior salto dos últimos cinco anos" na compreensão de linguagem pela Busca (GOOGLE, 2019).

Tradução automática

Até 2016, o Google Tradutor traduzia pedaço por pedaço da frase. Ao trocar para um modelo de tradução neural (GNMT), a Google mediu uma redução de 55% a 85% nos erros de tradução em vários pares de idiomas, avaliada por tradutores humanos comparando o resultado antigo com o novo (GOOGLE RESEARCH, 2016).

Chatbots de atendimento no Brasil

Aqui no Brasil, uma pesquisa destacada pelo portal E-Commerce Brasil aponta que 69% dos consumidores preferem ser atendidos por chatbot quando a dúvida é simples e rápida — exatamente o tipo de tarefa em que PLN básico (entender a pergunta, casar com uma resposta pronta) já resolve bem (E-COMMERCE BRASIL, 2024).

E ainda tem mais

Sem estatística de manchete, mas igual de presentes no seu dia a dia:

- **Corretor ortográfico** — sugestão de correção enquanto você digita, no celular ou no editor de texto;
- **Legendas automáticas** — geradas em tempo real em vídeos, streams e transmissões;
- **Moderação de conteúdo** — detecção automática de discurso de ódio, spam e conteúdo impróprio;
- **Classificação de spam** — separar e-mail relevante de spam, automaticamente;
- **Resumo automático** — reduzir um texto longo às informações principais;
- **Análise de sentimento** — empresas monitorando o que falam delas nas redes sociais;
- **Assistentes de voz** — Siri, Alexa e afins.

Todas nascem do mesmo problema de fundo que vamos estudar neste curso.

O desafio extra do português

A maior parte da pesquisa e das ferramentas prontas de PLN nasce pensando em inglês primeiro. O português traz complicações próprias (FERREIRA; LOPES, 2019):

- **Morfologia rica** — um verbo como "falar" tem dezenas de formas (falo, falei, falará, falasse...), contra bem menos em inglês;
- **Acentuação e cedilha** — "está" e "esta" são palavras diferentes; muita gente escreve sem acento no dia a dia;
- **Varição PT-BR vs. PT-PT** — vocabulário e até gramática mudam ("você" vs. "tu", "ônibus" vs. "autocarro");
- **Menos dados e ferramentas prontas** comparado ao inglês — muitas vezes é preciso adaptar ou treinar do zero.

PLN não é igual para todas as línguas

O avanço do PLN não é distribuído de forma uniforme entre os idiomas do mundo. Das mais de 7 mil línguas vivas faladas atualmente, um estudo de referência da área mostra que mais de 90% de todos os recursos de PLN — corpora, modelos, ferramentas — estão concentrados em menos de 20 línguas, e só sete delas (inglês, mandarim, espanhol, francês, alemão, japonês e árabe) têm recursos ricos o bastante para PLN de ponta (JOSHI et al., 2020).

O português brasileiro está numa posição relativamente confortável: existem modelos treinados especificamente para o idioma, como o BERTimbau (NEURALMIND-AI, 2020), e corpora consolidados como o Mac-Morpho, do NILC. Mesmo assim, ferramentas multilíngues costumam ter desempenho pior em português do que em inglês nas mesmas tarefas.

Já as línguas indígenas do Brasil — o país registra hoje 295 línguas indígenas faladas por 391 etnias (IBGE, 2025) — praticamente não aparecem nos dados usados para treinar os modelos que vamos usar neste curso. Não é uma escolha deliberada de excluí-las: é que não existem dados digitais suficientes nesses idiomas para treinar nada. Vale ter isso em mente ao longo do curso: as ferramentas com as quais trabalhamos carregam um viés de representação — e isso também é parte do que significa usar PLN de forma responsável.

A hierarquia da compreensão

Cada técnica que você vai aprender neste curso se encaixa em algum nível desta pirâmide — da unidade mais simples (a palavra) até o produto final (um chatbot, uma tradução automática):



Os cinco níveis da hierarquia da compreensão em PLN: morfológico, sintático, semântico, discursivo e aplicado

Hoje você só encosta no nível mais básico — no notebook, tokenizar um texto já é trabalhar no nível morfológico. Os demais níveis vão aparecer aos poucos, sessão a sessão, sempre com exemplo prático quando chegar a vez de cada um.

O pipeline que vamos construir ao longo do curso

Praticamente toda aplicação de PLN segue este caminho — e é exatamente a ordem em que veremos as próximas sessões:

1. **Processamento de texto** — limpar, tokenizar, normalizar (sessões 3 e 4);
2. **Extração de características** — transformar texto em números que um modelo entende (sessão 5);
3. **Análise sintática e semântica** — entender a estrutura e o sentido da frase (sessões 7 a 9);
4. **Descoberta de conhecimento e análise de sentimento** — extrair informação útil do texto (sessões 10 a 13);
5. **Aprendizagem de máquina, voz e chatbots** — colocar tudo isso para trabalhar junto (sessões 14 a 16).

Primeiros conceitos: por onde a máquina começa

Antes de abrir o notebook, três ideias que você vai usar direto hoje — o aprofundamento de cada uma vem na sessão 3, mas já vale entender o que elas significam:

- **Tokenização** — quebrar um texto em pedaços menores chamados *tokens* (palavras, pontuação). É o primeiro passo de quase todo pipeline de PLN: sem token, não tem o que contar ou analisar depois.
- **Segmentação de sentenças** — quebrar um texto em frases. Parece trivial ("separa pelo ponto final"), mas abreviações, números e siglas fazem um separador ingênuo errar em casos reais.
- **Frequência de palavras** — contar quantas vezes cada token aparece. É o jeito mais simples de começar a enxergar do que um texto trata — e também o primeiro lugar onde você esbarra em "ruído" (pontuação, palavras muito comuns) que ainda não sabe filtrar. Isso vira assunto oficial na sessão 3.

No notebook de hoje você aplica os três: tokeniza um texto real em português, separa em sentenças e conta as palavras mais frequentes — sem se preocupar ainda em limpar o resultado (HOBSON; COLE; HANNES, 2019).

Ferramentas que vamos usar

Ferramenta	Para quê
------------	----------

NLTK	Biblioteca clássica de PLN em Python — tokenização, corpora, exercícios didáticos
spaCy	PLN em produção — mais rápida, com modelo pronto para português
scikit-learn	Extração de características (TF-IDF) e modelos clássicos de aprendizagem de máquina
pandas	Organizar e explorar os dados de texto

ATIVIDADE DA SEMANA

Abra o notebook `introducao_pln.ipynb`. Ele te guia a instalar as bibliotecas, tokenizar seu primeiro texto em português e responder duas perguntas curtas de reflexão. Leva menos de uma hora — é só o primeiro contato, o aprofundamento vem na sessão 3.

Referências

Bibliografia da disciplina

- FERREIRA, M.; LOPES, M. *Para conhecer linguística computacional*. São Paulo: Contexto, 2019.
- HOBSON, L.; COLE, H.; HANNES, H. *Natural Language Processing in Action*. Manning, 2019.

Fontes citadas nesta sessão

- FERREIRA; LOPES. Sinopse oficial de *Para conhecer linguística computacional*. Disponível em: https://books.google.com/books/about/Para_conhecer_linguistica_computacional.html?id=odtFEQAAQBAJ.
- GOOGLE. *Understanding searches better than ever before*. The Keyword, 2019. Disponível em: <https://blog.google/products-and-platforms/products/search/search-language-understanding-bert/>.
- GOOGLE RESEARCH. *A Neural Network for Machine Translation, at Production Scale*. Google Research Blog, 2016. Disponível em: <https://research.google/blog/a-neural-network-for-machine-translation-at-production-scale/>.
- E-COMMERCE BRASIL. *69% dos consumidores preferem ser atendidos através de chatbots*. 2024. Disponível em: <https://www.ecommercebrasil.com.br/noticias/69-dos-consumidores-prefere-m-ser-atendidos-atraves-de-chatbots>.
- CASELI, H. M.; NUNES, M. G. V. (org.). *Processamento de Linguagem Natural: conceitos, técnicas e aplicações em português*. BPLN, 2023. Disponível em: <https://brasileiraspln.com/livro-pln/2a-edicao/>.
- JOSHI, P. et al. *The State and Fate of Linguistic Diversity and Inclusion in the NLP World*. Proceedings of the 58th Annual Meeting of the ACL, 2020. Disponível em: <https://aclanthology.org/2020.acl-main.560/>.

- NEURALMIND-AI. *BERTimbau: Pretrained BERT Models for Brazilian Portuguese*. 2020. Disponível em: <https://huggingface.co/neuralmind/bert-base-portuguese-cased> .
- IBGE. *Censo Demográfico 2022 — línguas indígenas faladas no Brasil*. 2025. Disponível em: <https://agenciabrasil.ebc.com.br/geral/noticia/2025-10/ibge-391-etnias-indigenas-falam-295-linguas-no-brasil> .