

O que é PLN, na prática?

Não é promessa de futuro. É o que já roda por trás de coisas que você usa todo dia — com fonte pra provar.



O que é PLN?

PLN é a área da Inteligência Artificial que ensina computadores a ler, entender, gerar e responder linguagem humana — a mesma que você usa pra falar e escrever, cheia de ambiguidade, gírias e exceções, bem diferente de uma linguagem de programação.

Isso não é teoria distante — você já usa PLN o tempo todo, mesmo sem perceber:

Busca

Tradução

Corretor ortográfico

Chatbot

Assistente de voz

e bem mais — a lista completa está no próximo slide

E POR TRÁS DE CADA FRASE QUE VOCÊ ESCREVE, ISSO:

Esse

atendimento

foi

incrível

pron.

subst.

verbo

adj.

(FERREIRA; LOPES, 2019)

Direto do livro-texto


“A todo momento, estamos às voltas com programas de computador que interpretam e produzem texto e fala, corrigem o que digitamos, sugerem possibilidades de expressão, dialogam, traduzem, classificam dados linguísticos e buscam informações em gigantescos bancos de dados. Tudo isso faz parte do universo da Linguística Computacional e do processamento de linguagem natural.”

FERREIRA, M.; LOPES, M. Para conhecer linguística computacional. Contexto, 2019 – sinopse oficial

[books.google.com – id=odtFEQAAQBAJ](https://books.google.com?id=odtFEQAAQBAJ)

Repare: interpretar e produzir texto e fala, corrigir digitação, sugerir expressão, dialogar, traduzir, classificar, buscar informação — sete aplicações de PLN numa frase só.

PLN existe na fronteira de três campos



O problema que o PLN resolve

DADO ESTRUTURADO

Formato predefinido — linhas e colunas de uma tabela, campos com tipo e relação conhecidos de antemão.

DADO NÃO ESTRUTURADO

Não segue esquema nenhum — um e-mail, um laudo médico, uma avaliação, um post. Significado exige interpretação.

80–90%

de todos os dados produzidos no mundo são não estruturados — a maior parte, em forma de texto (CASELI; NUNES, 2023).

Um hospital pode ter milhões de prontuários digitalizados — mas perguntas simples como “quantos pacientes com mais de 60 anos tiveram certo sintoma nos últimos 5 anos?” seguem sem resposta se ninguém processar o texto.

Sem PLN, esse volume de dados é computacionalmente invisível.

Por que isso é difícil

AMBIGUIDADE LEXICAL

“manga”

Fruta ou parte de uma roupa? Só o contexto resolve.

AMBIGUIDADE SINTÁTICA

“vi o cachorro correndo”

Quem estava correndo — eu ou o cachorro?

IRONIA

“atendimento maravilhoso, esperei 2h”

Sentimento oposto ao literal.

CONTEXTO E REFERÊNCIA

“Maria chegou. Ela estava atrasada.”


O computador precisa saber que “ela” é a Maria.

VARIAÇÃO E INFORMALIDADE

“vc tá bem?”

Gírias regionais, erros de digitação propositais ou não.

PLN não nasceu com o ChatGPT



Neste curso passamos pela evolução na prática: regras → estatística (TF-IDF, embeddings) → aprendizagem de máquina aplicada a PLN.

(FERREIRA; LOPES, 2019; HOBSON; COLE; HANNES, 2019)

Isso já roda na sua busca



processamento de linguagem natural

entendido como frase inteira

BERT · Google Search

1 em 10

buscas em inglês nos EUA passaram a ser entendidas de outro jeito quando o Google trocou para o BERT, em out/2019 — “o maior salto dos últimos cinco anos”.

fonte: blog.google — GOOGLE, 2019

E na tradução automática



Até 2016: tradução pedaço por pedaço.

Com rede neural: a frase inteira de uma vez.

55–85%

menos erros de tradução em vários pares de idiomas, medido por tradutores humanos comparando com o sistema neural (GNMT).

fonte: research.google – GOOGLE RESEARCH, 2016

E no atendimento, aqui no Brasil

qual o prazo de entrega?

chega em até 5 dias úteis :)

perfeito, obrigado!

69%

dos consumidores brasileiros preferem ser atendidos por chatbot quando a dúvida é simples e rápida.

fonte: ecommercebrasil.com.br — E-COMMERCE BRASIL, 2024

E ainda tem mais

Sem estatística de manchete, mas igual de presentes no seu dia a dia:

Corretor ortográfico

Sugestão de correção enquanto você digita, no celular ou no editor de texto.

Legendas automáticas

Geradas em tempo real em vídeos, streams e transmissões.

Moderação de conteúdo

Deteção automática de discurso de ódio, spam e conteúdo impróprio.

Classificação de spam

Separar e-mail relevante de spam, automaticamente.

Resumo automático

Reduzir um texto longo às informações principais.

Análise de sentimento

Empresas monitorando o que falam delas nas redes sociais.

O desafio extra do português

Morfologia rica

“Falar” tem dezenas de formas — falo, falei, falará, falasse... bem mais que em inglês.

Acentuação e cedilha

“Está” e “esta” são palavras diferentes; muita gente escreve sem acento no dia a dia.

PT-BR vs. PT-PT

Vocabulário e gramática mudam: “você” vs. “tu”, “ônibus” vs. “autocarro”.

Menos dados prontos

A pesquisa nasce pensando em inglês primeiro — muitas vezes é preciso adaptar ou treinar do zero.

PLN não é igual para todas as línguas

>90%

dos recursos de PLN (corpora, modelos, ferramentas) concentrados em menos de 20 línguas — só 7 têm recursos ricos o bastante para PLN de ponta (JOSHI et al., 2020).

PORTUGUÊS BRASILEIRO

Posição relativamente confortável: BERTimbau (NEURALMIND-AI, 2020) e corpora como o Mac-Morpho. Mesmo assim, atrás do inglês nas mesmas tarefas.

LÍNGUAS INDÍGENAS DO BRASIL

295 línguas indígenas faladas por 391 etnias no Brasil hoje (IBGE, 2025) — praticamente ausentes dos dados usados para treinar os modelos que vamos usar. Não é exclusão deliberada: é que não existe dado digital suficiente nesses idiomas. As ferramentas com que trabalhamos carregam um viés de representação — isso também é usar PLN de forma responsável.

A hierarquia da compreensão



O pipeline do curso



Praticamente toda aplicação de PLN segue este caminho — é a ordem exata das próximas sessões.

Primeiros conceitos: por onde a máquina começa

- **Tokenização**

Quebrar um texto em pedaços menores — tokens (palavras, pontuação). Sem token, não tem o que contar ou analisar depois.

- **Segmentação de sentenças**

Quebrar um texto em frases. Abreviações, números e siglas fazem um separador ingênuo errar.

- **Frequência de palavras**

Contar quantas vezes cada token aparece — o jeito mais simples de enxergar do que um texto trata.

No notebook de hoje você aplica os três, sem se preocupar ainda em limpar o resultado — isso vira assunto oficial na sessão 3.

Ferramentas e atividade da semana

NLTK

Biblioteca clássica de PLN em Python — tokenização, corpora, exercícios didáticos

spaCy

PLN em produção — mais rápida, com modelo pronto para português

scikit-learn

Extração de características (TF-IDF) e modelos clássicos de aprendizagem de máquina

pandas

Organizar e explorar os dados de texto

ATIVIDADE DA SEMANA

`introducao_pln.ipynb`

Instala as bibliotecas, tokeniza seu primeiro texto em português e responde duas perguntas curtas de reflexão.

Leva menos de uma hora — é só o primeiro contato, o aprofundamento vem na sessão 3.

Referências

BIBLIOGRAFIA DA DISCIPLINA

FERREIRA, M.; LOPES, M. Para conhecer linguística computacional. São Paulo: Contexto, 2019.

HOBSON, L.; COLE, H.; HANNES, H. Natural Language Processing in Action. Manning, 2019.

CASELI, H. M.; NUNES, M. G. V. (org.). Processamento de Linguagem Natural: conceitos, técnicas e aplicações em português. BPLN, 2023.

FONTES CITADAS NESTA SESSÃO

FERREIRA; LOPES. Sinopse oficial do livro-texto — books.google.com

GOOGLE. Understanding searches better than ever before, 2019 — blog.google

GOOGLE RESEARCH. A Neural Network for Machine Translation, 2016 — research.google

E-COMMERCE BRASIL. 69% preferem ser atendidos por chatbots, 2024 — ecommercebrasil.com.br

JOSHI et al. The State and Fate of Linguistic Diversity in the NLP World, 2020 — aclanthology.org

NEURALMIND-AI. BERTimbau, 2020 — huggingface.co

IBGE. Censo Demográfico 2022 — línguas indígenas, 2025 — agenciabrasil.ebc.com.br